Energy-style research manuscript | Polished v2

小样本电池 SOH 估计中物理趋势约束与融合域对齐的泛化边界

Generalization limits of physics-guided trend constraints and fusion-domain alignment for small-sample battery SOH estimation

Anonymous author(s) | affiliations withheld for double-blind review

ARTICLE INFO

Keywords:
Lithium-ion battery
State of health
Small-sample learning
Physical consistency
Domain shift
Negative transfer

ABSTRACT

Small-sample lithium-ion battery state-of-health (SOH) estimation is limited not only by scarce labels but also by cross-cell distribution shift and error accumulation during recursive extrapolation. We froze a G-MTC forecasting backbone comprising SCF-GAN augmentation, seasonal-trend decomposition using Loess (STL), TimesNet/iTransformer component predictors, and Attention Bi-LSTM fusion, and established an auditable protocol without test-set tuning. Two removable interventions were then evaluated independently: monotonicity and smoothness penalties applied only to the predicted STL Trend component, and covariance-invariant latent alignment (CILA) applied to the existing fusion context. B0007 and B0018 followed a labeled 60/20/20 adaptation protocol and therefore did not constitute zero-label cross-cell transfer. After configuration locking, B0043 and B0044 were evaluated once as outer batteries using five random seeds. The baseline passed leakage and metric-recomputation checks, but the median B0018 RMSE was 5.1367%, compared with 0.9123% reported in the source paper; CNN also outperformed the Transformer-family comparators in the present implementation. Trend constraints reduced RMSE for selected batteries and seeds but did not jointly satisfy the preregistered accuracy, physical-consistency, and time-block bootstrap criteria. CILA produced median gains below 0.001 percentage points on the development batteries and failed outer confirmation on B0044, where only two of five seeds improved, the paired median difference was +0.000689 percentage points, and the 95% confidence interval crossed zero. These observations do not support a stable cross-cell advantage for either intervention. Instead, they identify recursive component extrapolation as a bottleneck that local regularization and downstream alignment could not reliably repair. The study contributes an auditable boundary analysis rather than a selectively optimized state-of-the-art claim.

中文摘要

小样本锂离子电池健康状态（state of health, SOH）估计不仅受标签稀缺影响，还受跨电池分布偏移和递归外推误差累积制约。本文以 SCF-GAN、季节-趋势分解（STL）、TimesNet/iTransformer 分支预测和 Attention Bi-LSTM 融合组成的 G-MTC 为冻结主干，建立无测试集调参、可逐循环重算的复现实验。随后分别检验两项可移除的最小干预：仅作用于 STL Trend 预测的单调/平滑物理约束，以及作用于既有融合上下文的协方差不变潜表示对齐（CILA）。B0007 和 B0018 采用前 60%有标签适配、20%验证和后 20%测试；该协议不是零标签跨电池迁移。配置锁定后，B0043 和 B0044 作为外层电池各执行一次五随机种子评估。基线通过数据泄漏和指标重算门禁，但 B0018 中位 RMSE 为 5.1367%，未达到原论文 0.9123% 的报告值；在当前实现中，CNN 也优于 Transformer 类比较模型。Trend 约束在部分电池和种子中降低 RMSE，却没有同时满足两电池准确率、物理一致性和时间块 bootstrap 门槛。CILA 在开发电池上的中位改善小于 0.001 个百分点，并在 B0044 外层评估中仅有 2/5 种子改善，配对中位差为 +0.000689 个百分点，95%置信区间跨越 0。结果不支持两项干预具有稳定的跨电池优势，而将上游分量递归外推识别为优先于局部正则和下游对齐的工程瓶颈。本文提供的是可反驳、可审计的适用边界证据，而非以选择性结果宣称新的最低误差。

1. 引言

锂离子电池 SOH 描述可用容量相对额定或初始容量的保持程度，是寿命预测、维护决策和安全控制的关键状态量。数据驱动模型避免了显式求解复杂电化学方程，但其可信度依赖于带标签退化轨迹的数量、训练与部署分布的一致性，以及模型在生命周期后段的外推稳定性。公开数据通常只包含少量实验室电芯，实际电池系统还会经历温度、负载和充电片段变化。因此，单一数据集或单个随机种子上的低误差不足以支持部署层面的泛化结论。

Yang 等提出的 G-MTC 使用 SCF-GAN 扩充健康特征，以 STL 将 SOH 分解为 Trend、Seasonal 和 Residual，并分别使用 TimesNet、TimesNet 和 iTransformer 建模，最后通过 Attention Bi-LSTM 融合分量预测[1]。该框架的重要性质不是所有分量都单调，而是不同分量承担不同时间尺度：Trend 表征长期衰减，Seasonal 表征周期波动，Residual 容纳随机扰动和容量再生。由此，物理先验应作用于 Trend，而不应把最终 SOH 强制为严格单调。

原论文在多个数据集上报告低于 1%的 RMSE，但没有公开源码，且若干网络层级、损失权重和数据切分细节未完全披露。因此，“实现了论文主方法路径”与“复现了论文数值”必须分别验证。近期 SOH 研究还显示，跨工况域偏移、无标签目标电池和现场部分充电是现实难点[2-7]。这些研究为物理先验和域对齐提供了动机，却不能预先保证它们在冻结 G-MTC 上有效。

本文围绕一个可证伪问题展开：在不替换 TimesNet、iTransformer、Attention Bi-LSTM 或 SCF-GAN 的条件下，Trend 物理约束或融合域对齐能否在固定协议中稳定改善跨电池 SOH 估计？本文的贡献包括：（1）区分方法符合性、数值复现和比较模型排序，建立逐循环可重算的可信基线；（2）实现只作用于连续 Trend 轨迹的单调/平滑损失；（3）在不改变预测主干的条件下检验 CILA；（4）以五随机种子、配对差和未接触外层电池保留负结果，明确两项干预的适用边界。

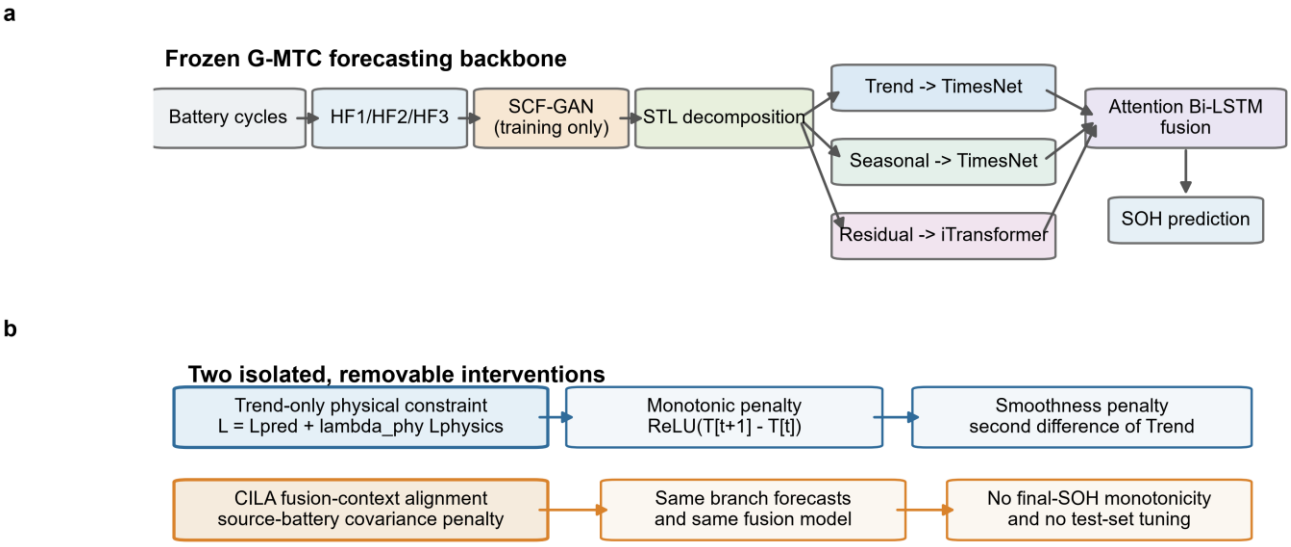


图 1 | 冻结 G-MTC 主干与两项隔离干预。a，SCF-GAN 仅增强训练数据；STL Trend 和 Seasonal 由 TimesNet 建模，Residual 由 iTransformer 建模，三分量进入 Attention Bi-LSTM 融合。b，物理损失只约束 Trend 预测，CILA 只约束融合上下文；两者均不约束最终 SOH，也不使用测试集调参。

2. 方法

2.1 数据、健康特征与划分

NASA Ames PCoE 数据包含逐循环电压、电流、温度和放电容量记录[15]。SOH 按当前放电容量相对额定容量计算。依据原论文提取三个充电时间特征：HF1 为恒流充电开始至电压首次达到 4.2 V 的时长；HF2 为达到 4.2 V 后至电流下降至 20 mA 截止点的时长；HF3 为电压由 3.8 V 上升至 4.0 V 的时长。HF2 的截止电流搜索严格从 4.2 V 到达点之后开始，避免把早期低电流噪声识别为恒压终点。

样本按 BatteryID、DatasetID 和 Cycle 排序。B0005 和 B0006 仅用于 SCF-GAN 源训练；B0007 不进入源预训练。B0007 和 B0018 分别按生命周期前 60%、随后 20%和最后 20%划分训练适配、验证和测试。标准化器、STL 拟合、特征处理和 GAN 增强均限制在训练前缀，滑动窗口不得跨越边界。由于目标电池前缀包含 SOH 标签，该协议是小样本有标签适配，而非零标签跨电池迁移。

2.2 冻结 G-MTC 基线

STL 将观测 SOH 写为 y=T+S+R。Trend 和 Seasonal 分别输入原始 TimesNet 路径，Residual 输入 iTransformer；分量预测与历史上下文进入 Attention Bi-LSTM 并生成最终 SOH。P0 为论文接近实现；P1 仅加入固定随机种子、梯度裁剪、验证早停、训练前缀标准化和数值稳定初始化。P1 不改变主架构，所有稳定化措施均与论文原始方法分开记录。

原论文未公开完整源码，因此 SCF-GAN 层宽、iTransformer 细节、融合上下文和部分辅助损失属于工程近似。本文不把“主路径已实现”表述为源代码级完全复刻。

2.3 Trend-only 物理约束

对同一 BatteryID 和 DatasetID 内 Cycle 连续的 Trend 预测 T_hat 计算单调项

L_mono = mean[ReLU(T_hat(t+1)-T_hat(t))]

和平滑项

L_smooth = mean[(T_hat(t+1)-2T_hat(t)+T_hat(t-1))^2]。

总损失为 L_total=L_prediction+lambda_phy L_physics 。physics_mode 支持 none、monotonic、smooth 和 both；lambda_phy 支持 0、0.001、0.01 和 0.1。物理损失从不在 shuffle 后的随机样本之间计算，也不施加于最终 SOH。Trend violation rate 定义为连续预测点中 T_hat(t+1)>T_hat(t)+epsilon 的比例，并与正向跳变幅度共同保存。

2.4 CILA 融合上下文对齐

CILA 只使用 Attention Bi-LSTM 已有融合上下文 Z_b。对两个训练电池域，计算均值和协方差差异：

L_align=‖mu_1-mu_2‖_2^2+‖C_1-C_2‖_F^2/(4d^2)，

其中 d 为上下文维数。融合目标为 L=L_prediction+lambda_weight L_weight+lambda_align L_align 。Original 令 lambda_align=0 ；CILA 的 lambda_align=0.1 和 lambda_weight=0.1 仅由验证集锁定。两种模式共享分量输入、初始化、种子、150 轮上限和早停耐心 30。

2.5 评估与成功门槛

固定随机种子为 42、52、62、72 和 82。报告 RMSE、MAE、MAPE 和 R^2，并从保存的逐循环预测重新计算。Trend 实验还报告 Trend violation rate。配对时间序列采用 5000 次圆形时间块 bootstrap 估计 RMSE 差的 95%置信区间。

Trend 创新需同时满足：B0007 和 B0018 中位 RMSE 均低于 Original；每个目标电池至少 3/5 种子改善；Trend 违规率或正向跳变下降；MAE、MAPE 和 R^2无明显恶化；bootstrap 方向支持改善。CILA 外层确认同样要求逐电池配对方向和至少 3/5 种子改善。B0007 和 B0018 是已接触开发电池；B0043 和 B0044 仅在配置锁定后执行一次正式外层评估。

3. 结果

3.1 可信基线未实现数值复现

五个种子均完成训练，无 NaN 或数值发散。硬性泄漏检查通过，原始 TimesNet、iTransformer 和 Attention Bi-LSTM 路径均参与计算。逐循环重算与保存指标的最大差异为 1.32e-05，因此 BaselineComplete 为 true。

可信过程没有转化为论文数值匹配。B0018 中位 RMSE 为 5.1367%，中位 R^2为-9.5473，而原论文分别报告 0.9123%和 0.8765，故 PaperNumericMatched 为 false（表 1）。在相同工程协议下，CNN 在 B0007 和 B0018 的中位 RMSE 分别为 0.6755%和 2.6151%，均低于 LSTM、Transformer 和当前 G-MTC。因此 TransformerBestObserved 为 false。Attention 三分支均参与融合，但 10 个电池-种子组合中 9 个近似静态，动态权重行为仍属于工程近似。

表 1 冻结 G-MTC 五随机种子结果

电池	RMSE 均值±标准差/%	RMSE 中位数/%	MAE 均值/%	MAPE 均值/%	R^2中位数
B0007	5.9110±1.9770	5.2050	5.1995	7.2238	-22.1318
B0018	5.1770±0.5758	5.1367	4.6910	6.7648	-9.5473

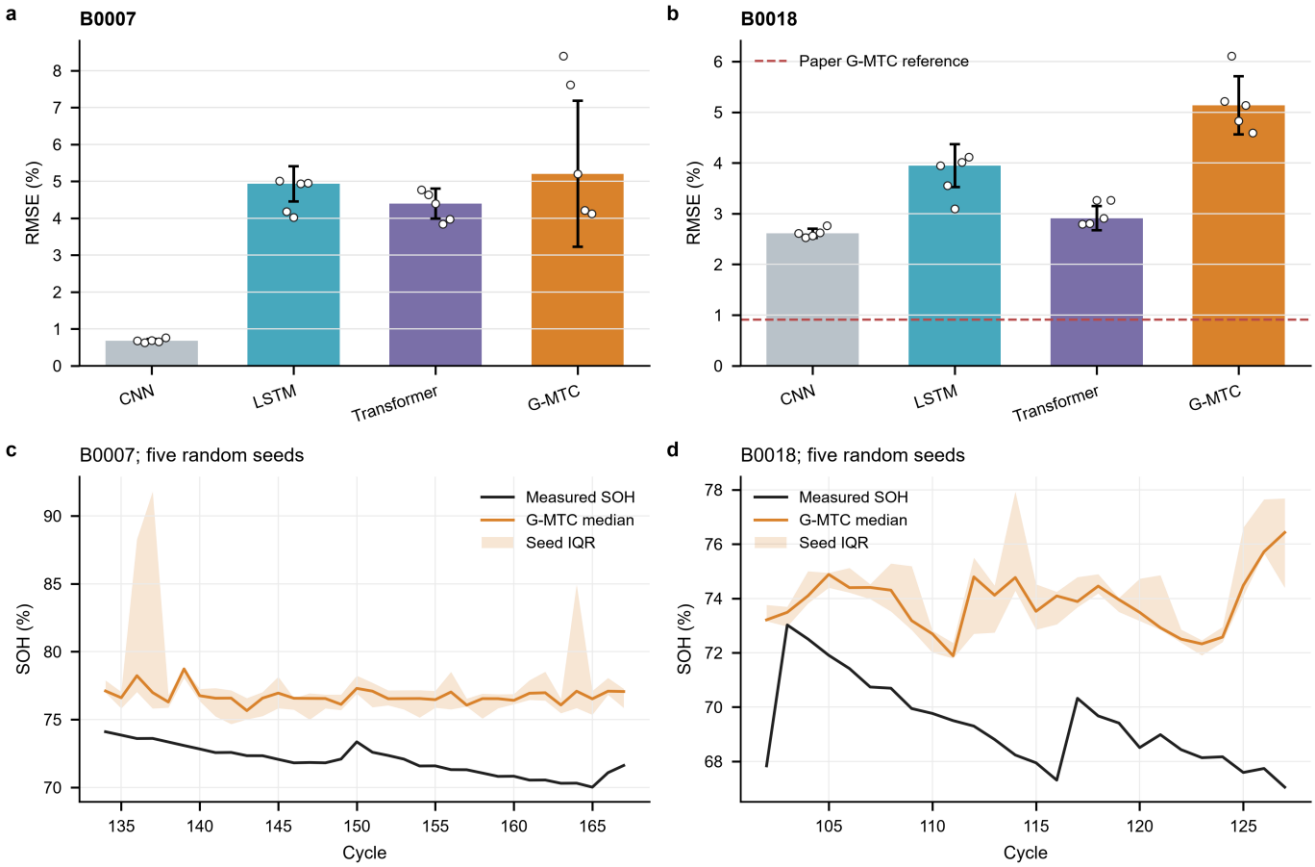


图 2 | 可信基线的数值差距。a-b，各模型五随机种子的 RMSE；柱为中位数，误差线为一个种子标准差，空心点为单个种子。B0018 红色虚线为原论文 G-MTC 参考 RMSE 0.9123%。c-d，冻结 G-MTC 逐循环预测；橙线和阴影分别为五种子中位数和四分位距，黑线为实测 SOH。

3.2 Trend 约束呈现电池与种子依赖性

验证集选择 lambda_phy=0.1 后，正式测试只改变 physics_mode。both 使 B0007 中位 RMSE 由 5.2050%降至 5.0157%，且 4/5 种子改善；但 B0018 仅 2/5 种子改善。monotonic 在 B0018 有 4/5 种子改善，却使 B0007 中位 RMSE 升至 5.9450%，并出现单种子严重失稳。没有一种模式同时通过两电池联合门槛（表 2）。

表 2 Trend-only 物理约束五随机种子消融

电池	模式	RMSE 中位数/%	RMSE 均值±标准差/%	Trend 违规率均值	改善种子
B0007	Original	5.2050	5.9110±1.9770	0.0545	-
B0007	Monotonic	5.9450	8.4873±7.1560	0.1212	2/5
B0007	Smooth	5.2186	4.9721±1.1966	0.0788	3/5
B0007	Both	5.0157	4.6723±0.9630	0.0788	4/5
B0018	Original	5.1367	5.1770±0.5758	0.0880	-
B0018	Monotonic	4.9920	5.1754±0.6830	0.1040	4/5
B0018	Smooth	5.1393	5.1767±0.9149	0.1200	2/5
B0018	Both	4.8323	5.0926±0.9422	0.0720	2/5

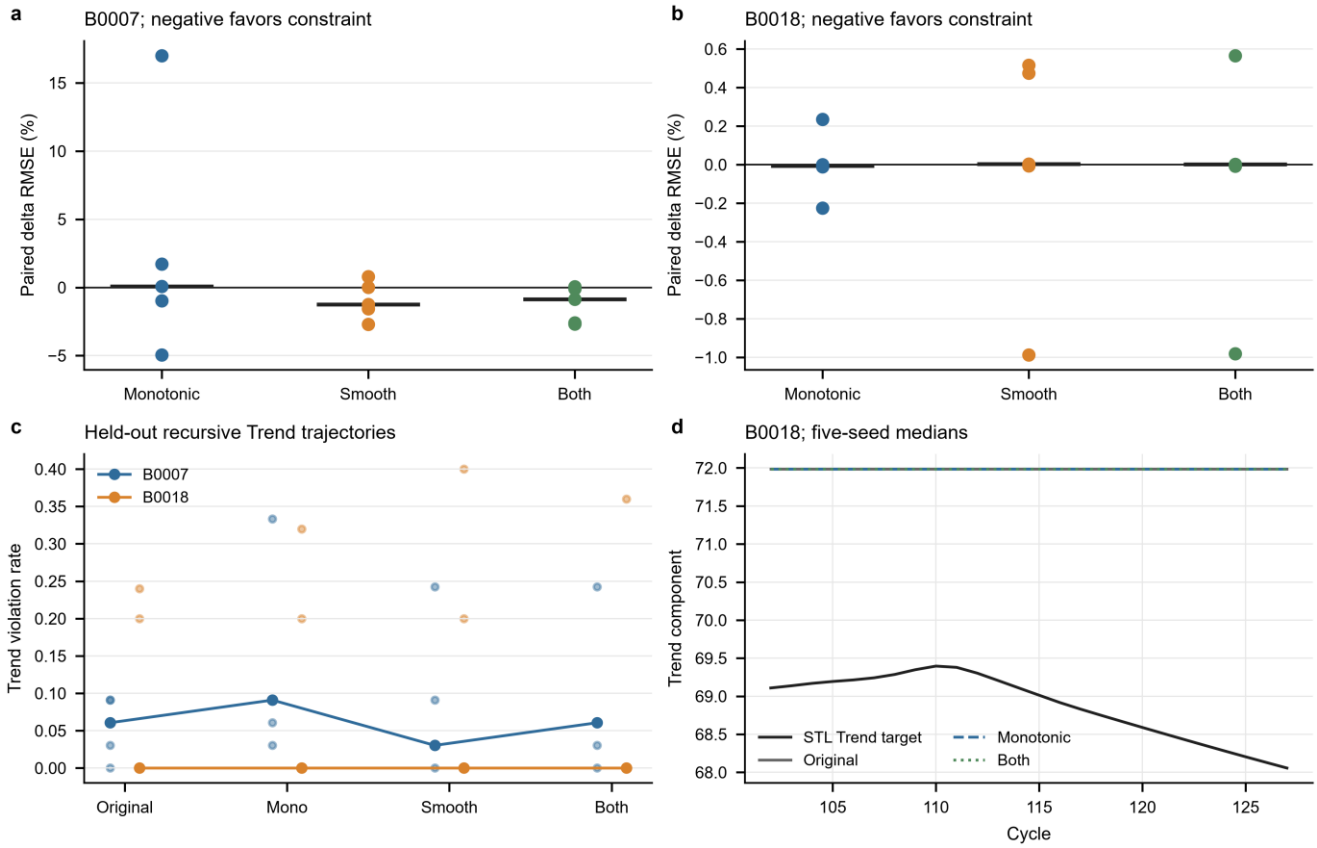


图 3 | Trend-only 物理约束的隔离消融。a-b，五个固定种子相对 Original 的配对 RMSE 差，负值表示改善，黑横线为中位数。c，各模式的测试期 Trend violation rate；实心点为中位数，淡点为单个种子。d，B0018 五种子 Trend 预测中位数；多条预测线在约 72 附近重合，显示递归分支的近常数输出而非物理约束优势。

3.3 CILA 未通过外层联合确认

在已接触的 B0007 和 B0018 上，CILA 的配对中位 RMSE 差分别为-0.000100 和-0.000786 个百分点。方向虽为改善，但实际幅度均小于 0.001 个百分点，不能据此宣称具有工程意义。

外层评估的结论更严格。B0043 有 3/5 种子改善，配对中位差为-0.001025 个百分点，95%时间块 bootstrap 区间为[-0.283230,-0.000313]。B0044 仅 2/5 种子改善，配对中位差为+0.000689 个百分点，区间[-0.002632,+0.001013]跨越 0（表 3）。因此 CILAInnovationSupported 为 false。

表 3 CILA 正式外层评估

电池	Original 中位 RMSE/%	CILA 中位 RMSE/%	配对中位差/%	改善种子	95%时间块 bootstrap 区间	判定
B0043	134.255705	134.254680	-0.001025	3/5	[-0.283230,-0.000313]	方向通过，效应可忽略
B0044	60.856165	51.303511	+0.000689	2/5	[-0.002632,+0.001013]	失败

不同方法的非配对中位数可能来自不同随机种子，不能替代同一种子内的配对差。逐循环误差还显示，部分分量递归预测偏离真实尺度达数百至数千个百分点。CILA 只调整融合上下文，无法从已经失真的分量输入恢复真实 SOH。

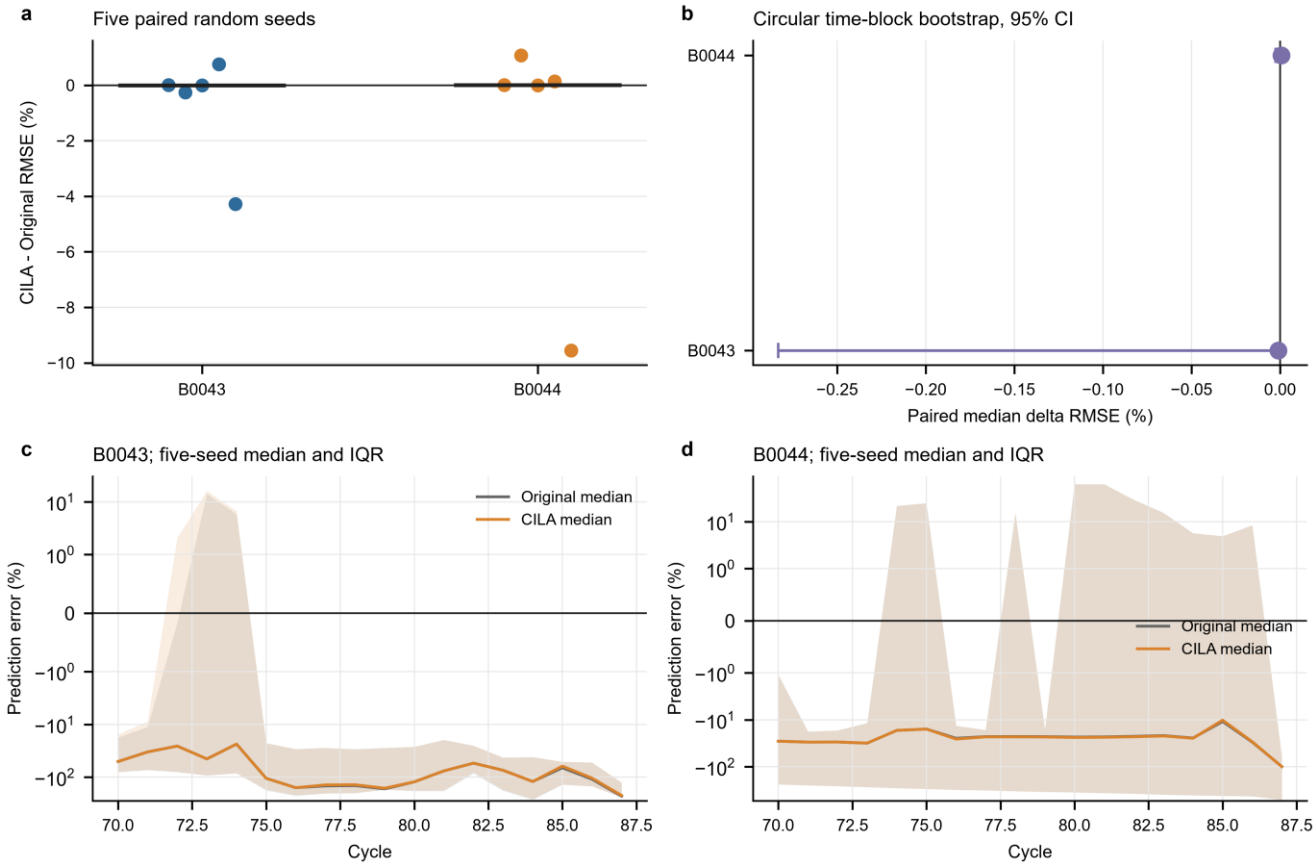


图 4 | CILA 外层电池确认。a，五个固定种子的配对 RMSE 差，负值有利于 CILA。b，5000 次圆形时间块 bootstrap 得到的配对中位差及 95%置信区间。c-d，五种子逐循环预测误差的中位数与四分位距，纵轴采用对称对数尺度以同时呈现误差方向和递归失稳幅度。

4. 讨论

4.1 方法符合性、数值匹配与模型排序是三个问题

本研究的基线在数据边界、主路径执行、多种子训练和指标重算方面可审计，但没有复现原论文数值。两者并不矛盾：在作者源码、精确划分和完整超参数缺失时，主架构复现可以成立，数值复现仍可能失败。当前 CNN 优于 Transformer 类模型也不是对原论文结论的普遍否定，只说明“Transformer 必然最好”没有在本实现和协议中被观察到。

4.2 更平滑不等于更准确

Trend 单调和平滑先验具有合理物理动机，但测试期表现还受 STL 边界、窗口长度和递归状态传播影响。某些种子中违规率下降而 RMSE 未下降，表明预测可能更平滑却仍存在水平偏差；另一些种子中 RMSE 下降但违规率上升，表明准确率与物理指标存在有限样本权衡。最终 SOH 包含 Seasonal 和 Residual，局部容量再生可能是真实信号，因此把单调性扩展到最终输出不是对负结果的合法补救。

4.3 下游对齐不能修复上游外推失稳

CILA 假设训练电池间的二阶统计差异包含可去除的域偏移。当域差异与衰减阶段、尺度或分量误差耦合时，对齐可能同时削弱 SOH 信息。更直接的限制是，CILA 位于融合端；若 Trend、Seasonal 或 Residual 已经发生数量级偏移，融合只能重加权错误输入，无法恢复缺失的真实轨迹。由此得到的“上游分量外推是瓶颈”是由错误传播位置支持的机制性推断，而不是已由新干预证明的因果结论。

4.4 对 SOH 论文设计的启示

第一，必须明确目标域标签使用方式，60/20/20 有标签适配不能表述为零标签迁移。第二，比较模型应在同一数据边界、同一特征和多随机种子下评估，网络名称不构成性能先验。第三，跨电池结论应报告逐电池配对差和未接触外层结果，合并平均值可能掩盖负迁移。第四，外层失败后不应继续针对同一电池试到成功；新的分支稳定化假设需要新的预注册外层数据。

5. 局限性

本研究仅使用 NASA 实验室数据，外层电池仍来自同一归档，不能代表跨机构、跨化学体系或真实车队。B0007 和 B0018 在项目开发中已被反复接触，只能支持开发性结论。B0043 和 B0044 从通过健康特征和窗口可行性检查的电池中选取，存在可用性选择偏差，但筛选发生在模型推理前。外层只有两个电池，bootstrap 区间描述的是已保存轨迹和种子配对的不确定性，不是现场电池总体置信区间。

原论文未公开源码，部分 SCF-GAN、iTransformer 和融合细节为工程近似。外层递归误差较大，使均值对单种子失稳敏感，因此本文同时报告中位数、单种子点和配对差。最后，正式外层失败后没有继续试验新的分支稳定化方案，避免把 B0043 和 B0044 转化为新的调参集。

6. 结论

本文在冻结 G-MTC 主架构、禁止测试集调参和保留失败记录的条件下，完成了可信基线、Trend-only 物理约束和 CILA 融合域对齐的多种子评估。基线在审计层面完成，但没有匹配原论文 RMSE 和 R^2，Transformer 也不是当前比较中的最佳模型。Trend 约束和 CILA 均在局部条件下出现改善，却未通过预注册的跨电池联合门槛。

因此，本研究不支持“新增模块稳定降低 SOH RMSE”的强结论。现有证据更一致地表明：当分量递归外推失稳时，局部 Trend 正则和下游融合对齐难以提供可重复收益。该负结果界定了方法适用范围，并为下一轮只检验一个上游外推稳定化因素、使用新的未接触外层数据提供可审计起点。

数据、代码与声明

实验使用 NASA 公开电池老化数据。代码、配置、训练日志、逐循环预测、失败尝试和结果汇总保存在项目输出目录；数据归档不随仓库重新分发。作者、单位、资助、利益冲突和 CRediT 贡献须由研究团队在投稿前据实补充。本稿在语言组织、代码审计和图表生成中使用 OpenAI Codex 及本地学术工作流；全部数值均

来自保存的实验文件并经过程序重算，最终解释和投稿责任由人类作者承担。

参考文献

[1] H. Yang et al., “Data-augmented SOH estimation for lithium-ion batteries under small-sample conditions: A hybrid STL-transformer-TimesNet approach,” Energy, vol. 342, 139463, 2026, doi: 10.1016/j.energy.2025.139463.

[2] M. Miao, C. Xiao, and J. Yu, “Multisource domain metalearning network for battery state-of-health estimation under multitarget working conditions,” IEEE Trans. Power Electron., 2025, doi: 10.1109/TPEL.2025.3538469.

[3] C. Song, H. Yuan, G. Wang, and N. Cui, “State of health estimation for lithium-ion battery with label-free data based on deep domain feature independent alignment network,” IEEE Trans. Power Electron., 2025, doi: 10.1109/TPEL.2025.3580291.

[4] W. Yao et al., “State of health estimation of lithium-ion batteries using data augmentation and feature mapping,” IEEE Trans. Transp. Electrific., vol. 11, pp. 4895-4905, 2025, doi: 10.1109/TTE.2024.3471867.

[5] L. Luo et al., “Physics-informed deep gated recurrent unit network for lithium-ion battery state of health estimation under field conditions,” IEEE Trans. Transp. Electrific., 2026, doi: 10.1109/TTE.2026.3686077.

[6] M. Lin et al., “Transfer learning-based lithium-ion battery state of health estimation with electrochemical impedance spectroscopy,” IEEE Trans. Transp. Electrific., 2025, doi: 10.1109/TTE.2025.3533540.

[7] Z. Hui et al., “An innovative magnetic field sensor based method predicting lithium-ion battery state-of-health,” Proc. IEEE Sensors Applications Symposium, 2025, doi: 10.1109/SAS65169.2025.11105130.

[8] A. Tian et al., “A generic physics-informed neural network framework for lithium-ion batteries state of health estimation,” Energy, vol. 332, 137215, 2025, doi: 10.1016/j.energy.2025.137215.

[9] S. Wang et al., “A generalizable physics-informed neural network for lithium-ion battery SOH estimation utilizing partial charging segments,” J. Energy Chem., vol. 112, pp. 977-986, 2025.

[10] B. Sun and K. Saenko, “Deep CORAL: Correlation alignment for deep domain adaptation,” ECCV Workshops, pp. 443-450, 2016.

[11] H. Wu et al., “TimesNet: Temporal 2D-variation modeling for general time series analysis,” Proc. ICLR, 2023.

[12] Y. Liu et al., “iTransformer: Inverted Transformers are effective for time series forecasting,” Proc. ICLR, 2024.

[13] O. Das et al., “Battery time-series data augmentation using a GAF-based generative framework,” Proc. IEEE EUROCON, 2025, doi: 10.1109/EUROCON64445.2025.11073369.

[14] V. Dimitrievska et al., “Battery state of health estimation via federated learning on diverse data from multiple sources,” Proc. FLICS, 2026, doi: 10.1109/FLICS70075.2026.11621953.

[15] B. Saha et al., “Prognostics methods for battery health monitoring using a Bayesian framework,” IEEE Trans. Instrum. Meas., vol. 58, no. 2, pp. 291-296, 2009.

[16] V. Olivero-Ortiz et al., “Aging and performance analysis of 18650 lithium-ion cell capacity degradation: Data-driven insights and modeling,” IEEE Access, 2025, doi: 10.1109/ACCESS.2025.3636613.